

Dokumentacja Specyfikacji Wymagań SRS

Analiza sentymentu i tematów artykułów finansowych dotyczących spółek
notowanych na Giełdzie Papierów Wartościowych w Warszawie

Natalia Liszniańska, Mateusz Izydorczyk, Franciszek Zabłocki

Semestr Letni 2026

Spis treści

1	Wstęp	3
1.1	Idea projektu	3
1.2	Zakres systemu	3
1.3	Słownik podstawowych pojęć	4
2	Cele systemu	6
2.1	Cel główny	6
2.2	Cele szczegółowe	6
2.2.1	Automatyzacja agregacji danych	6
2.2.2	Lingwistyczne przygotowanie i standaryzacja tekstu	6
2.2.3	Algorytmiczne mapowanie podmiotów gospodarczych	6
2.2.4	Domonowo-leksykonowa analiza sentymentu	6
2.2.5	Eksploracja semantyczna i modelowanie tematyczne	6
2.2.6	Generowanie profili semantycznych spółek	7
2.2.7	Syntetyczna wizualizacja i raportowanie wyników	7
2.3	Kryteria sukcesu systemu	7
3	Wymagania funkcjonalne	8
3.1	Moduł pozyskiwania i zarządzania danymi	8
3.2	Moduł lingwistycznego przetwarzania tekstu	8
3.3	Moduł mapowania i analizy sentymentu	8
3.4	Moduł eksploracji statystycznej i modelowania tematycznego	9
3.5	Moduł wizualizacji i obsługi potoku analitycznego	9
4	Wymagania niefunkcjonalne	10
4.1	Niezawodność, odporność na błędy i jakość danych	10
4.2	Powtarzalność obliczeń i stabilność środowiskowa	10
4.3	Wydażność, skalowalność i obsługa języka polskiego	10

4.4	Utrzymywalność kodu, czytelność i granice systemu	11
4.5	Bezpieczeństwo	11
5	Interfejsy użytkownika i wymagania dotyczące danych	12
5.1	Charakterystyka interfejsu technicznego i prezentacji danych	12
5.2	Wymagania dotyczące danych wejściowych	12
5.3	Struktura danych pośrednich i słowników	13
5.4	Charakterystyka danych wyjściowych	13
6	Słownictwo dokumentacji	14
7	Przypadki użycia (use cases)	17
7.1	Scenariusze zasilania bazy danych i wyodrębnienia treści	17
7.2	Scenariusze lingwistycznego przygotowania danych i mapowania rynku	17
7.3	Scenariusze modelowania matematycznego i eksploracji Text Mining	17
7.4	Scenariusze prezentacji wyników i utrzymania ciągłości procesowej	18
8	Scenariusze użytkownika (user stories)	19
8.1	Automatyzacja agregacji danych i kontrola środowiska składowania	19
8.2	Lingwistyczne przygotowanie korpusu i mapowanie podmiotów GPW	19
8.3	Eksploracja statystyczna i matematyczne modelowanie tematów	19
8.4	Syntetyczne raportowanie i zarządzanie granicami systemu	20

1 Wstęp

1.1 Idea projektu

Dokument wprowadza w architekturę i wymagania systemu, którego zadaniem jest automatyczne przetwarzanie potoku wiadomości rynkowych oraz zestawianie i porównywanie wyekstrahowanych z nich sygnałów sentymentu z rzeczywistymi notowaniami na Giełdzie Papierów Wartościowych w Warszawie (GPW). Obecny rynek finansowy generuje ogromne ilości tak zwanego szumu informacyjnego; codziennie na portalach takich jak Bankier.pl publikowane są setki artykułów, komunikatów spółek i analiz makroekonomicznych. Głównym wyzwaniem badawczym i technologicznym jest zweryfikowanie, w jakim stopniu te medialne doniesienia korelują z faktycznymi ruchami cen akcji.

Specyfikacja Wymagań Systemowych (SRS) służy jako techniczny fundament projektu realizowanego w ramach przedmiotu **Projektowanie Systemów Informatycznych** w semestrze letnim 2026 na Wydziale Nauk Ekonomicznych Uniwersytetu Warszawskiego. Dokument ten ma za zadanie precyzować, jak surowy tekst z internetu staje się czystym punktem danych, definiuje granice działania algorytmów oraz określa kryteria, według których oceniana będzie skuteczność i wydajność całego potoku analitycznego.

1.2 Zakres systemu

Projektowany system to potok analityczno-obliczeniowy, którego głównym zadaniem jest przekształcanie nieustrukturyzowanych informacji tekstowych (dokładniej artykułów prasowych zawierających wiadomości z kraju i ze świata, analizy gospodarcze, informacje o inwestowaniu, finansach osobistych oraz rankingi produktów bankowych) w ustrukturyzowane wskaźniki ilościowe (sygnały sentymentu i klastry tematyczne) przypisane do konkretnych walorów giełdowych.

W skład zakresu systemu wchodzi następujące podsystemy:

- Moduł pozyskiwania danych odpowiada za zautomatyzowane pobieranie artykułów z serwisu Bankier.pl z wykorzystaniem kanałów RSS oraz mechanizmów pobierania danych archiwalnych. Moduł umożliwia zarówno analizę bieżących publikacji, jak i budowę retrospektywnego zbioru danych wykorzystywanego do analiz oraz walidacji wyników.
- Moduł identyfikacji spółek i tickerów odpowiada za rozpoznawanie podmiotów gospodarczych występujących w treści artykułów oraz przypisywanie im odpowiednich tickerów giełdowych GPW. Proces ten uwzględnia nazwy spółek, ich skróty oraz oznaczenia giełdowe.
- Moduł przetwarzania językowego odpowiada za przygotowanie tekstów do dalszej analizy poprzez czyszczenie treści, tokenizację, usuwanie słów stopu oraz wykorzystanie słowników dziedzinowych dostosowanych do języka finansowego i realiów rynku GPW.
- Moduł analityczno-statystyczny odpowiada za właściwą analizę przetworzonych danych tekstowych. W jego skład wchodzi następujące metody eksploracji tekstu:
 1. analiza sentymentu oparta na hybrydowym słowniku łączącym zasoby dostosowane do języka polskiego oraz pojęcia charakterystyczne dla rynku GPW,
 2. klastrowanie artykułów metodą k-średnich na podstawie reprezentacji TF-IDF,

3. modelowanie tematyczne metodą utajonej alokacji Dirichleta w celu identyfikacji głównych tematów i wątków pobocznych,
4. generowanie profili semantycznych spółek giełdowych na podstawie wag TF-IDF,
5. analiza frekwencyjna słów kluczowych oraz wizualizacja wyników w formie chmur słów.

Wyłączenia z zakresu:

Aby jasno określić granice projektu, chcemy podkreślić, że poza zakresem systemu pozostają kwestie związane z obsługą użytkowników, takie jak tworzenie modułów rejestracji, logowania czy zarządzania kontami. Nie budujemy również żadnego interfejsu graficznego (typu: aplikacji mobilnych czy stron internetowych) ponieważ system działa całkowicie w tle jako automatyczny potok danych. Ponadto program **nie generuje** gotowych porad inwestycyjnych typu „Kup” lub „Sprzedaj” akcje danej spółki, a jedynie analizuje teksty i bada panujące w nich nastroje. System **nie jest** także botem tradingowym, co oznacza, że **nie zawiera** żadnych automatycznych transakcji na prawdziwej giełdzie.

1.3 Słownik podstawowych pojęć

Tabela 1: Słownik pojęć i skrótów systemowych

Termin Akronim	Pełna nazwa	Definicja i kontekst systemowy
GPW	Giełda Papierów Wartościowych	Główny rynek regulowany w Warszawie, dla którego system generuje sygnały rynkowe.
SRS	<i>Software Requirements Specification</i>	Specyfikacja Wymagań Oprogramowania (dokument strukturalny).
Ticker	Identyfikator giełdowy	Unikalny, kilkuliterowy identyfikator skrótowy spółki notowanej na giełdzie (np. PKO, KGH, PKN).
TF-IDF	<i>Term Frequency - Inverse Document Frequency</i>	Statystyczna metoda obliczania wagi słów w tekście, odzwierciedlająca znaczenie wyrazu dla danego dokumentu w kontekście korpusu.
LDA	<i>Latent Dirichlet Allocation</i>	Probabilistyczny model generatywny umożliwiający odkrywanie ukrytych tematów w zbiorze dokumentów (<i>soft clustering</i>).
K-means	Algorytm k-średnich	Nienadzorowana metoda podziału obiektów na k rozłącznych klastrów na podstawie odległości euklidesowej (<i>hard clustering</i>).
LM-PL	Loughran & McDonald - wersja PL	Polskie tłumaczenie i adaptacja dziedzinowa słownika finansowego do kategoryzacji emocjonalnej słów (omawiany na zajęciach).

Tabela 1: Słownik pojęć i skrótów systemowych

Termin Akronim	Pełna nazwa	Definicja i kontekst systemowy
plWordNet	Słowosieć	Relacyjno-semantyczny leksykon języka polskiego, wykorzystywany do ekspansji synonimicznej słów.
Data Pipeline	Potok przetwarzania danych	Zautomatyzowany ciąg operacji (pobieranie, transformacja, analiza, zapis) realizowany bez interwencji ludzkiej.

2 Cele systemu

2.1 Cel główny

Głównym celem tego projektu jest automatyzacja tego procesu poprzez zbudowanie inteligentnego potoku danych (*data pipeline*). System ma za zadanie samodzielnie pobierać publikowane artykuły (zarówno te najnowsze, jak i te archiwalne), rozpoznawać, których spółek dotyczą, a następnie za pomocą metod matematycznych i lingwistycznych (od prostych leksykonów po zaawansowane modelowanie tematyczne LDA, które omówimy w dalszych rozdziałach) oceniać nastroje medialne wokół danych walorów oraz grupować wiadomości w kluczowe wątki rynkowe.

2.2 Cele szczegółowe

Droga do osiągnięcia celu głównego prowadzi przez realizację celów szczegółowych, które pokrywają się z kolejnymi modułami tworzonego potoku danych, które obejmują:

2.2.1 Automatyzacja agregacji danych

Napisanie skryptu, który będzie automatycznie zbierał teksty z Bankier.pl na dwa sposoby: najpierw pobierze starsze artykuły z archiwum (żebyśmy mieli na czym testować i uczyć algorytmy), a potem będzie na bieżąco sprawdzał kanały RSS, żeby wyłapywać najnowsze wiadomości zaraz po ich publikacji.

2.2.2 Lingwistyczne przygotowanie i standaryzacja tekstu

Stworzenie modułu, który oczyści pobrane artykuły ze wszystkiego, co zbędne, czyli usunie kod HTML, reklamy oraz poboczne informacje systemowe. Następnie program podzieli tekst na pojedyncze słowa, usunie najpopularniejsze wyrazy niezawierające emocji (tzw. słowa stopu, takie jak „i”, „w”, „na”) oraz ujednolici cały zapis, dzięki czemu algorytmy będą mogły pracować na czystym, gotowym do analizy materiale.

2.2.3 Algorytmiczne mapowanie podmiotów gospodarczych

Napisanie skryptu, który będzie automatycznie przeszukiwał teksty i rozpoznawał, o jakich firmach mowa. Program musi radzić sobie z pełnymi nazwami spółek, ich potocznymi skrótami oraz oficjalnymi tickerami z GPW (jak PKO czy KGH), a następnie samoczynnie łączyć dany artykuł z konkretną spółką w utworzonej bazie danych.

2.2.4 Domonowo-leksykonowa analiza sentymentu

Przygotowanie kodu, który będzie oceniał, czy dany artykuł ma charakter pozytywny, negatywny, czy neutralny. Zamiast zwykłego słownika językowego, program wykorzysta specjalną listę słów finansowych (dostosowaną do specyfiki języka polskiego i realiów GPW na wzór słownika Loughran & McDonald poznanego na zajęciach). Dzięki temu system poprawnie zinterpretuje giełdowe pojęcia i precyzyjnie określi nastroje panujące wokół spółek.

2.2.5 Eksploracja semantyczna i modelowanie tematyczne

Uruchomienie dwóch algorytmów, które pomogą automatycznie uporządkować zebrane artykuły:

- Algorytm K-means: Podzieli teksty na wyraźne, oddzielne grupy, łącząc ze sobą artykuły o bardzo podobnej treści (np. zbiór tekstów ściśle o raportach finansowych danej spółki).
- Modelowanie LDA: Przeanalizuje cały zbiór wiadomości, aby wyłapać ukryte, przewijające się w tle tematy i trendy (np. nagły wzrost liczby artykułów o inflacji czy dywidendach na całym rynku).

2.2.6 Generowanie profili semantycznych spółek

Zbudowanie funkcji, która sprawdzi, jakie konkretne słowa najczęściej pojawiają się przy danej firmie. System użyje do tego statystyk częstości wyrazów (TF-IDF), aby automatycznie wskazać, z jakimi wydarzeniami biznesowymi spółka kojarzy się w mediach. Na przykład, czy w artykułach o danym emitencie najczęściej pisze się o wypłacie dywidendy, fuzjach, czy może o kwartalnych wynikach finansowych.

2.2.7 Syntetyczna wizualizacja i raportowanie wyników

Przygotowanie czytelnego sposobu prezentacji wszystkich zebranych danych. System ma przedstawiać wyniki analiz w postaci przejrzystych tabel, wykresów korelacji, zestawień częstości słów oraz chmur słów (widocznych między innymi w raporcie HTML). Dzięki temu użytkownik będzie mógł szybko i łatwo zinterpretować przetworzone wiadomości oraz zobaczyć końcowe efekty działania programu.

2.3 Kryteria sukcesu systemu

System zostanie uznany za zrealizowany pomyślnie, jeśli spełni następujące kryteria techniczne i operacyjne:

1. Potok danych działa stabilnie i bezbłędnie na każdym etapie od pobrania surowego artykułu ze strony internetowej (scraping) aż po zapisanie końcowych wyników analizy tekstowej.
2. Moduł rozpoznawania firm poprawnie przypisuje spółki z GPW do artykułów, radząc sobie z ich skrótami oraz odmianą nazw własnych przez przypadki w języku polskim.
3. Algorytmy klastrowania (K-means oraz LDA) tworzą logiczne i spójne grupy tekstów, co pozwala łatwo wyodrębnić najważniejsze wątki rynkowe bez zbędnego szumu informacyjnego.

3 Wymagania funkcjonalne

Opisane poniżej wymagania funkcjonalne systemu zostały pogrupowane według kolejnych kroków transformacji informacji; od pobrania surowego tekstu z sieci, przez analizy statystyczno-językowe, aż po automatyczne wygenerowanie raportu końcowego.

3.1 Moduł pozyskiwania i zarządzania danymi

Podstawowym zadaniem systemu jest zautomatyzowane pozyskiwanie artykułów finansowych z serwisu Bankier.pl. Proces ten opiera się na dwóch równoległych mechanizmach: ciągłym monitorowaniu bieżących kanałów RSS w celu wyłapywania najnowszych wiadomości oraz masowym scrapowaniu zasobów archiwalnych portalu, co pozwala zbudować szeroką bazę historyczną do dalszych analiz. Podczas pobierania każdego artykułu program automatycznie wyodrębnia i trwale zapisuje kluczowe metadane, w tym: tytuł oraz pełną treść artykułu, dokładną datę i godzinę publikacji, adres URL oraz lead (krótki opis wstępny) i opcjonalnie informacje o autorze lub kategorii tematycznej.

Przed zapisaniem danych system przeprowadza automatyczną walidację pobranych rekordów. W przypadku wykrycia błędów, takich jak uszkodzony link, pusta treść czy błędy odpowiedzi serwera (np. 404), dany artykuł jest oznaczany jako niepoprawny lub pomijany. Gwarantuje to, że kolejne moduły pracują wyłącznie na danych o wysokiej jakości analitycznej.

Zgromadzone pliki są przechowywane w ustrukturyzowany sposób, z wyraźnym podziałem na warstwę surową (`raw_data`) oraz przetworzoną. Umożliwia to przyrostową aktualizację bazy danych, dzięki czemu użytkownik może pobrać najnowsze wiadomości bez konieczności ponownego ściągania całego archiwum od początku.

3.2 Moduł lingwistycznego przetwarzania tekstu

Po poprawnym zapisaniu artykułów system uruchamia proces przetwarzania wstępnego (*preprocessing*). Jego głównym celem jest oczyszczenie surowej treści ze wszystkiego, co zbędne z punktu widzenia dalszej analizy. Skrypty automatycznie usuwają z tekstu znaczniki HTML, nadmiarowe białe znaki, znaki specjalne oraz wszelki "szum techniczny" powstały podczas scrapowania stron internetowych.

Ujednolicony w ten sposób tekst zostaje poddany tokenizacji, czyli podziałowi na pojedyncze słowa. Następnie algorytm filtruje korpus i eliminuje z niego tzw. słowa stopu, czyli wyrazy bardzo częste, ale niewnoszące żadnej wartości emocjonalnej (np. spójniki i przyimki). Co ważne, lista wykluczeń obejmuje zarówno ogólne słowa stopu dla języka polskiego, jak i specyficzne zwroty charakterystyczne dla domeny finansowej, co zapobiega zniekształceniu wyników końcowych.

3.3 Moduł mapowania i analizy sentymentu

Kluczowym elementem funkcjonalnym systemu jest powiązanie artykułów z realnymi podmiotami rynkowymi. Odpowiada za to dedykowany skrypt `src/data_ingestion/assign_tickers.R`, który automatycznie przeszukuje teksty pod kątem obecności spółek notowanych na Giełdzie Papierów Wartościowych w Warszawie. Mechanizm ten został zaprojektowany tak, aby z wysoką precyzją

rozpoznawać oficjalne tickery giełdowe (np. PKO, KGH), skróty biznesowe oraz pełne nazwy prawne firm, radząc sobie przy tym z polską odmianą nazw własnych przez przypadki.

Gdy artykuł zostanie przypisany do właściwej spółki, moduł `src/sentiment.R` realizuje słownikową klasyfikację wydźwięku tekstu. System oblicza udział słów pozytywnych oraz negatywnych, przypisując każdej wiadomości końcową kategorię sentymentu: pozytywną, negatywną lub neutralną. Zamiast ogólnego słownika językowego, model ten wykorzystuje dedykowaną listę terminów finansowych (będącą adaptacją założeń słownika Loughran & McDonald do realiów GPW). Pozwala to na poprawną interpretację specyficznego żargonu ekonomicznego. Dodatkowo system oferuje funkcję agregacji tych wskaźników, umożliwiając śledzenie średniego nastroju wokół konkretnych spółek lub całego rynku w wybranym przedziale czasu.

3.4 Moduł eksploracji statystycznej i modelowania tematycznego

W ramach głębszej analizy tekstowej, system przekształca oczyszczone słowa w wartości numeryczne, obliczając dla nich reprezentację statystyczną TF-IDF. Miara ta pozwala określić, które pojęcia są unikalne i najważniejsze dla konkretnego artykułu na tle całego korpusu danych. Na podstawie tych wag moduł `src/clustering.R` realizuje dwa zaawansowane zadania analityczne; po pierwsze jest to klastrowanie metodą k-średnich, które automatycznie grupuje artykuły o bardzo zbliżonej treści w rozłączne zbiory, wskazując słowa kluczowe najlepiej opisujące dany węzeł tematyczny. Po drugie modelowanie tematów (LDA), które z kolei wykorzystuje algorytm probabilistyczny do wykrywania ukrytych wątków przewijających się w tle komunikatów, co pozwala przypisać dokumentom prawdopodobieństwo przynależności do wielu tematów jednocześnie.

Oprócz ogólnego podziału tekstów, system potrafi autonomicznie generować tzw. profile semantyczne dla poszczególnych emitentów. Poprzez analizę częstości współwystępowania wyrazów, program ujawnia główny kontekst biznesowy (np. wypłata dywidendy, wyniki finansowe), w jakim dana spółka najczęściej pojawia się w mediach.

3.5 Moduł wizualizacji i obsługi potoku analitycznego

Ostatnim etapem działania systemu jest prezentacja zebranych rezultatów oraz generowanie czytelnych i estetycznych wizualizacji danych. Wyniki są przedstawiane w formie wykresów rozkładu sentymentu w czasie, tabel częstości, map klastrów oraz chmur słów. Wszystkie te elementy są automatycznie kompilowane przy użyciu narzędzia R Markdown do jednego, przejrzystego raportu końcowego w formacie HTML, który można otworzyć w dowolnej przeglądarce internetowej.

Cały potok danych został zaprojektowany z myślą o powtarzalności i stabilności działania. Użytkownik ma możliwość uruchomienia całego procesu (od scrapingu po raport) w uporządkowanej kolejności za pomocą jednego wywołania. System posiada wbudowane mechanizmy odporności na błędy i obsługi wyjątków; w przypadku wystąpienia problemu z pojedynczym plikiem lub braku pojedynczego wpisu, program informuje o tym w logach, ale nie zatrzymuje działania całego potoku, kontynuując analizę na pozostałych, poprawnych artykułach.

4 Wymagania niefunkcjonalne

Wymagania niefunkcjonalne, które tu opiszymy, definiują charakterystykę jakościową systemu, określając standardy, w jakich środowisko analityczne musi operować. Skupiają się one na aspektach stabilności, wydajności, utrzymywalności kodu oraz precyzji przetwarzania języka naturalnego, co bezpośrednio gwarantuje rzetelność i powtarzalność generowanych wyników statystycznych.

4.1 Niezawodność, odporność na błędy i jakość danych

System musi charakteryzować się wysoką odpornością na błędy sieciowe oraz strukturalne anomalie danych wejściowych. Awaria pojedynczego zapytania HTTP, brak określonych metadanych (np. informacji o autorze) czy uszkodzony format konkretnego artykułu na portalu Bankier.pl **nie mogą** doprowadzić do przerwania wykonywania data pipeline. Program ma za zadanie automatycznie izolować wadliwe wpisy, logować błędy do celów diagnostycznych i kontynuować przetwarzanie na pozostałym, poprawnym korpusie tekstów.

W celu zapewnienia wiarygodności końcowych wniosków statystycznych, system wdraża rygorystyczne kryteria kontroli jakości danych. Algorytmy czyszczące i filtrujące eliminują duplikaty wiadomości, puste rekordy oraz błędy techniczne powstałe podczas scrapowania stron. Przepływ informacji pomiędzy kolejnymi modułami potoku opiera się na ścisłej integralności danych, to znaczy: format wyjściowy wygenerowany przez jeden skrypt musi być w pełni kompatybilny z oczekiwaniami wejściowymi następnego modułu.

4.2 Powtarzalność obliczeń i stabilność środowiskowa

Kluczowym z naszej perspektywy wymaganiem jest także pełna reprodukowalność wyników. Ze względu na wykorzystanie metod probabilistycznych i statystycznych (m.in. klastrowanie K-means czy modelowanie tematyczne LDA), system musi gwarantować determinizm obliczeń. Każde uruchomienie potoku danych na tym samym zbiorze wejściowym, przy zachowaniu identycznych parametrów, musi generować identyczne lub bezpośrednio porównywalne struktury tematów i wskaźniki sentymentu. Cel ten jest realizowany w kodzie poprzez jawne inicjalizowanie generatorów liczb pseudolosowych.

Pod względem technologicznym oprogramowanie musi również cechować się wysoką mobilnością w obrębie środowiska projektowego. System powinien dać się uruchomić na standardowej stacji roboczej użytkownika po spełnieniu zdefiniowanych zależności bibliotecznych środowiska R. Struktura katalogów została zaprojektowana przy użyciu ścieżek względnych, co eliminuje konieczność ręcznej modyfikacji kodu po przeniesieniu projektu na inny komputer. Ponadto, system zachowuje bezwzględną zasadę separacji danych: surowe pliki pobrane z sieci (**raw_data**) są odizolowane od przetworzonych macierzy oraz plików wynikowych, co pozwala na bezpieczne, wielokrotne testowanie algorytmów.

4.3 Wydajność, skalowalność i obsługa języka polskiego

Mimo że system powstał jako projekt akademicki, jego wydajność musi umożliwiać automatyczne przetwarzanie dużych zbiorów tekstów bez nadmiernego obciążania sprzętu. Operacje preprocesingowe, wektoryzacja TF-IDF, obliczanie macierzy częstości oraz generowanie wykresów muszą

wykonywać się w akceptowalnym czasie i w sposób w pełni zautomatyzowany. System umożliwia łatwe rozszerzanie zbioru danych bez konieczności przebudowy kodu.

Bardzo ważnym elementem jest prawidłowa obsługa języka polskiego. Wszystkie części programu; od pobierania artykułów po tworzenie raportu muszą korzystać z kodowania UTF-8. Dzięki temu system nie „popsuje” polskich liter (takich jak „ą”, „ę”, „ł”, „ó”), co jest niezbędne, aby algorytmy mogły poprawnie dzielić tekst na słowa, sprawdzać ich wydźwięk w słownikach i liczyć statystyki.

4.4 Utrzymywalność kodu, czytelność i granice systemu

Konstrukcja kodu źródłowego opiera się na formule modułów. Funkcje i skrypty są logicznie podzielone na katalogi odpowiadające konkretnym krokom (np. pobieranie, analiza sentymentu, klastrowanie). Nazewnictwo zmiennych, funkcji oraz plików jest intuicyjne i bezpośrednio odzwierciedla ich rolę w systemie, a kluczowe operacje matematyczne i lingwistyczne zostały opatrzone dodatkowymi komentarzami. Taki układ pozwala na łatwą konserwację oprogramowania, szybką lokalizację potencjalnych błędów oraz bezproblemową rozbudowę o nowe moduły w przyszłości.

Ostatnim istotnym aspektem systemu jest zapewnienie pełnej interpretowalności wyników poprzez warstwę prezentacji wykonaną w formacie HTML i generowaną za pomocą R Markdown. Ta część musi cechować się wysoką estetyką, przejrzystym układem graficznym oraz logiczną kolejnością sekcji. Wyniki analiz nie mogą przyjmować formy surowych macierzy matematycznych, tylko muszą być zaprezentowane za pomocą czytelnych tabel, wykresów korelacji oraz chmur słów, umożliwiając natychmiastową ocenę nastrojów giełdowych przez czytelników.

4.5 Bezpieczeństwo

W zakresie bezpieczeństwa system operuje wyłącznie na publicznie dostępnych danych tekstowych z portalu Bankier.pl i nie wymaga pobierania, przechowywania ani przetwarzania żadnych danych osobowych użytkowników. Ewentualne nazwiska autorów lub personelu spółek traktowane są wyłącznie jako surowy ciąg znaków wewnątrz analizowanego tekstu źródłowego.

5 Interfejsy użytkownika i wymagania dotyczące danych

System analizy sentymentu artykułów giełdowych nie stanowi klasycznej aplikacji wyposażonej w rozbudowany, okienkowy interfejs graficzny (GUI). Ze względu na swój badawczo-analityczny charakter, środowiskiem pracy użytkownika jest bezpośrednio struktura katalogów projektu, pliki skryptów języka R oraz generowane automatycznie raporty statystyczne. Interfejs systemu ma zatem profil techniczno-analityczny, ukierunkowany na czytelność przesyłu informacji w ramach data pipeline.

5.1 Charakterystyka interfejsu technicznego i prezentacji danych

Głównym punktem interakcji operatora z systemem jest środowisko programistyczne, w którym uruchamiane są poszczególne moduły kodu. Użytkownik zarządza pracą programu poprzez sekwencyjne lub całościowe wywoływanie skryptów odpowiedzialnych za pobieranie danych, preprocessing, klasyfikację emocjonalną oraz modelowanie statystyczne. Kluczowym elementem tego interfejsu jest przejrzysta i intuicyjna architektura katalogów projektu, która pozwala na natychmiastowe zorientowanie się w strukturze projektu i sprawną kontrolę nad przebiegiem eksperymentu.

Najważniejszą warstwę prezentacji wyników dla odbiorcy końcowego stanowi autonomicznie generowany raport w formacie HTML, który jest kompilowany przy użyciu pakietu R Markdown i może być otwarty w dowolnej standardowej przeglądarce internetowej, bez konieczności posiadania specjalistycznego oprogramowania czy środowiska uruchomieniowego języka R. Raport pełni funkcję kompletnego podsumowania menedżersko-analitycznego. Zawiera on czytelny opis analizowanej próby badawczej, zastosowaną metodologię naukową oraz zarówno interaktywne, jak i statyczne tabele oraz wykresy. Każda wizualizacja (w tym chmury słów czy wykresy korelacji) posiada jednoznaczny tytuł, opis osi oraz legendę, co ułatwia interpretację danych.

Ostatnim elementem interfejsu są komunikaty diagnostyczne generowane w trakcie wykonywania potoku danych. W przypadku wystąpienia anomalii (takich jak brak dostępu do sieci, puste pliki wejściowe czy błędy w strukturze HTML serwisu Bankier.pl) system generuje w konsoli zrozumiałe dla użytkownika komunikaty błędów. Pozwalają one precyzyjnie zlokalizować, który moduł (np. scraping czy sentyment) napotkał problem, ułatwiając diagnostykę bez przerywania pracy całego środowiska. System celowo nie implementuje paneli logowania, kont użytkowników ani baz uprawnień, co redukuje złożoność architektoniczną i pozwala w pełni skupić się na celach analitycznych.

5.2 Wymagania dotyczące danych wejściowych

Jak już wyżej zostało to wspomniane dane wejściowe systemu stanowią publicznie dostępne artykuły finansowe pozyskiwane z portalu Bankier.pl za pomocą kanałów RSS oraz skryptów przeszukujących zasoby archiwalne. Każdy dokument wprowadzany do systemu musi być reprezentowany przez zestaw ustrukturyzowanych metadanych. Program wyodrębnia ze struktury strony tytuł, unikalny adres URL, dokładną datę publikacji, lead (krótkie wprowadzenie) oraz pełną treść właściwą artykułu. System dopuszcza sytuację, w której niektóre pola opcjonalne (np. nazwisko autora) są niedostępne; w takim przypadku są one odpowiednio flagowane, by nie zakłócać pracy algorytmów. Poza tym, surowe dane wejściowe są trwale zapisywane w dedykowanej lokalizacji (`data/raw_data`) w swojej pierwotnej postaci tekstowej. Odizolowanie ich od dalszych etapów przetwarzania jest kluczowe dla zachowania integralności projektu, umożliwiając wielokrotne uruchamianie poprawionych skryptów lingwistycznych na tym samym, nienaruszonym materiale źródłowym.

5.3 Struktura danych pośrednich i słowników

Dane pośrednie powstają dynamicznie w trakcie transformacji tekstu przez potok analityczny. Obejmują one m.in. oczyszczone ciągi znaków, zwektoryzowane listy tokenów, tabele częstości występowania wyrazów oraz macierze matematyczne TF-IDF. Przekazywanie danych między modułami (np. ze skryptu preprocessingowego do modułu klastrowania) wymaga zachowania bezwzględnej spójności formatów, ze szczególnym uwzględnieniem kodowania UTF-8. Poprawna obsługa polskich znaków diakrytycznych na etapie danych pośrednich decyduje o skuteczności całego potoku przetwarzania.

Istotnym komponentem systemu są dane słownikowe, przechowywane w osobnych plikach w katalogu projektu. Rozwiązanie to pozwala na aktualizację zasobów leksykalnych bez konieczności modyfikacji logiki programistycznej w skryptach R. System operuje na trzech typach baz słownikowych:

Słowniki słów stopu: zawierające polskie wyrazy ogólne oraz specyficzne frazy techniczne filtrowane z tekstu,

Finansowe słowniki sentymentu: klasyfikujące słowa pod kątem ich emocjonalnego nacechowania giełdowego (pozytywne, negatywne, neutralne),

Baza emitentów GPW: rejestr oficjalnych tickerów, pełnych nazw prawnych oraz skrótów handlowych spółek, umożliwiający poprawne mapowanie i grupowanie odmian fleksyjnych nazw firm na jeden, unikalny identyfikator giełdowy.

5.4 Charakterystyka danych wyjściowych

Dane wyjściowe stanowią finalny produkt działania potoku analitycznego i są zapisywane w strukturze katalogu wynikowego w celu ich potencjalnego wykorzystania w zewnętrznych arkuszach kalkulacyjnych lub bazach danych. W skład zbioru wyjściowego wchodzi obliczone wartości sentymentu dla poszczególnych artykułów (wyrażone miarami udziału słów nacechowanych), tablice przypisań dokumentów do konkretnych klastrów tematycznych algorytmu K-means oraz wektory prawdopodobieństwa tematów pobocznych wyznaczonych przez model LDA.

Integralną częścią danych wyjściowych są wyrenderowane pliki graficzne wykresów i map semantycznych, które system trwale zapisuje na dysku oraz osadza w końcowym raporcie HTML. Spójność danych od surowego pliku wejściowego, przez transformacje pośrednie, aż po sformatowane tabele wyjściowe raportu, pozwala uznać strukturę informacyjną systemu za kompletną, zamkniętą i w pełni weryfikowalną.

6 Słownictwo dokumentacji

Rozdział rozwija i poszerza listę definicji kluczowych pojęć, terminów technicznych oraz skrótów algorytmicznych zawartych w rozdziale 1. Wstęp i wykorzystywanych w niniejszej specyfikacji SRS oraz w dokumentacji technicznej kodu źródłowego. Celem poniższego zestawienia jest ujednolicenie stosowanej terminologii, wyeliminowanie niejasności interpretacyjnych oraz zapewnienie spójnego zrozumienia architektury systemu.

Analiza frekwencyjna Badanie statystyczne polegające na zliczaniu bezwzględnej lub względnej częstości występowania poszczególnych tokenów w analizowanym korpusie tekstowym lub jego wyodrębnionych podzbiorach (np. dla konkretnej spółki).

Analiza sentymentu (*Sentiment Analysis*) Proces ilościowego i jakościowego określania oraz klasyfikacji emocjonalnego wydźwięku tekstu. W ramy systemu wchodzi kategoryzacja dokumentów na klasy: pozytywną, negatywną lub neutralną.

Artykuł finansowy Pojedyncza, wyodrębniona publikacja tekstowa pozyskana z portalu źródłowego, zawierająca treść właściwą oraz przypisany do niej zestaw ustrukturyzowanych metadanych.

Bankier.pl Portal internetowy o profilu finansowo-gospodarczym, stanowiący dla systemu zewnętrzne, pierwotne źródło danych wejściowych.

Chmura słów (*Word Cloud*) Graficzna forma wizualizacji danych tekstowych, w której wielkość (font) poszczególnych słów jest bezpośrednio proporcjonalna do ich częstości występowania lub wagi statystycznej w analizowanym zbiorze.

Dane przetworzone Dane tekstowe i numeryczne, które zostały poddane pełnemu potokowi czyszczenia, normalizacji oraz tokenizacji, uzyskując strukturę gotową do bezpośredniego zasilenia algorytmów eksploracyjnych.

Dane surowe (*Raw data*) Dane pozyskane bezpośrednio z serwisu zewnętrznego w formacie źródłowym (np. czysty kod HTML), przed nałożeniem jakichkolwiek filtrów lingwistycznych, zawierające szum techniczny i reklamowy.

Dane wejściowe Wszelkie informacje wprowadzane do systemu przed rozpoczęciem procesów przetwarzania; w kontekście tego projektu są to surowe artykuły giełdowe wraz z protokołami sieciowymi.

Dane wyjściowe Finalne produkty działania systemu, do których zalicza się obliczone wektory sentymentu, tabele przypisań do klastrów, profile semantyczne emitentów, pliki graficzne oraz skompilowany raport HTML.

GPW Giełda Papierów Wartościowych w Warszawie S.A. główny rynek regulowany instrumentów finansowych w Polsce, stanowiący punkt odniesienia dla bazy identyfikowanych emitentów.

Klaster Wydzielony, spójny semantycznie zbiór dokumentów tekstowych, wyodrębniony przez algorytm uczenia nienadzorowanego na podstawie podobieństwa matematycznego.

Klastrowanie (*Clustering*) Matematyczna metoda podziału obiektów (tutaj: artykułów) na grupy (klastry) w taki sposób, aby elementy wewnątrz jednej grupy były jak najbardziej podobne do siebie, a elementy z różnych grup jak najbardziej się różniły.

LDA (*Latent Dirichlet Allocation*) Utażona Alokacja Dirichleta probabilistyczny model generatywny wykorzystywany do automatycznego modelowania tematycznego. Pozwala na określenie struktury ukrytych wątków oraz przypisanie dokumentom rozkładu prawdopodobieństwa przynależności do nich.

Mapowanie tickerów Proces algorytmicznego dopasowywania wykrytych w tekście nazw własnych, skrótów handlowych oraz form odmienionych do jednego, unikalnego identyfikatora giełdowego spółki.

Metada Zbiór ustrukturyzowanych informacji opisujących dany dokument, uzupełniających jego treść właściwą (np. sygnatura czasowa, autor, unikalny adres URL, sekcja tematyczna).

Metoda k-średnich (*K-means*) Algorytm nienadzorowanego uczenia maszynowego służący do twardego podziału danych na z góry określoną liczbę k rozłącznych klastrów poprzez minimalizację odległości obiektów od środków ciężkości (centroidów).

Modelowanie tematyczne (*Topic Modeling*) Technika z zakresu eksploracji tekstu służąca do odkrywania ukrytych struktur abstrakcyjnych tematów w dużym zbiorze dokumentów.

Pipeline analityczny (Potok danych) Sekwencyjny, w pełni zautomatyzowany ciąg operacji technologicznych i obliczeniowych, w którym dane wyjściowe jednego modułu są bezpośrednio danymi wejściowymi kolejnego etapu.

Profil semantyczny spółki Unikalny zestaw słów kluczowych i kontekstów biznesowych najsilniej powiązanych z danym emitentem na podstawie statystycznej analizy współwystępowania wyrazów.

Raport HTML Końcowy dokument analityczny generowany automatycznie przy użyciu środowiska R Markdown, agregujący pełne wyniki działania systemu w czytelnej formie wizualnej i tabelarycznej.

RSS (*Really Simple Syndication*) Oparty na języku XML protokół przesyłu nagłówek wiadomości i metadanych, wykorzystywany przez system do ciągłego monitorowania i pobierania najnowszych publikacji.

Scraping (*Web Scraping*) Technologia automatycznego pobierania i ekstrakcji danych z kodu źródłowego stron internetowych z pominięciem standardowego interfejsu użytkownika.

Sentymet Wartościujący lub emocjonalny ładunek tekstu, określający stosunek autora lub opisywanego otoczenia do danej sprawy; w projekcie wyrażany w kategoriach giełdowych (optymizm/pesymizm rynkowy).

Słowa stopu (*Stop words*) Wyrazy o bardzo wysokiej częstotliwości występowania w języku naturalnym, które nie niosą ze sobą samodzielnej wartości informacyjnej (np. zaimki, spójniki, partykuły), usuwane na etapie preprocessingu.

Słownik sentymentu Leksykon dziedzinowy zawierający sklasyfikowane pod względem emocjonalnym tokeny; w systemie używana jest adaptacja słownika Loughran & McDonald dostosowana do specyfiki polskiej nomenklatury GPW.

Spółka giełdowa (Emitent) Podmiot prawa handlowego, którego papiery wartościowe są dopuszczone do obrotu na rynku regulowanym giełdy.

TF-IDF (*Term Frequency – Inverse Document Frequency*) Statystyczna metoda ważenia częstości słów, odzwierciedlająca znaczenie danego wyrazu w dokumencie przy jednoczesnym uwzględnieniu jego unikalności w skali całego analizowanego korpusu.

Ticker Unikalny, kilkuliterowy kod identyfikacyjny przypisany papierom wartościowym danej spółki na giełdzie (np. PKO, KGH, PKN).

Token Podstawowa, niepodzielna jednostka tekstu (najczęściej pojedyncze słowo), wyodrębniona w procesie tokenizacji w celu dalszego przetwarzania statystycznego.

Tokenizacja Lingwistyczny proces podziału ciągłego strumienia tekstu na sekwencję pojedynczych, autonomicznych jednostek leksykalnych (tokenów).

Użytkownik systemu Osoba odpowiedzialna za inicjalizację potoku danych, konfigurację parametrów eksperymentu lub bezpośredni odbiorca raportu końcowego (np. prowadzący zajęcia, deweloper).

Wizualizacja danych Przekształcenie surowych struktur numerycznych oraz tabel statystycznych w formę graficzną w celu ułatwienia natychmiastowej interpretacji zależności w danych.

7 Przypadki użycia (use cases)

Rozdział ten opisuje interakcję użytkownika (analityka lub badacza) z potokiem danych. Ponieważ system nie jest aplikacją wielodostępną, przypadki użycia skupiają się na wywoływaniu konkretnych skryptów programistycznych. Głównym celem operacyjnym jest przetworzenie surowych komunikatów medialnych w ustrukturyzowaną wiedzę o nastrojach rynkowych.

7.1 Scenariusze zasilania bazy danych i wyodrębnienia treści

Pierwsza grupa interakcji obejmuje procesy pozyskiwania i strukturyzacji materiału badawczego. Użytkownik inicjuje potok danych, decydując o horyzoncie czasowym analizy. W scenariuszu monitorowania bieżącego (*UC-01: Pozyskanie bieżących artykułów*), system łączy się z kanałami RSS serwisu Bankier.pl, pobierając nagłówki i podstawowe metadane najnowszych publikacji. Program automatycznie weryfikuje unikalność sygnatur URL, dzięki czemu nowo napływające dane są bezkonfliktowo doklejane do istniejącego archiwum bez ryzyka powstawania duplikatów.

Do zbudowania bazy historycznej służy funkcja pobierania danych z archiwum (*UC-02*), która automatycznie zbiera odnośniki do artykułów z przeszłości. Powiązany z nią moduł parsowania (*UC-03*) analizuje kod HTML każdej strony. System odcina od właściwej treści elementy zbędne, takie jak; reklamy, menu i komentarze użytkowników, po czym zapisuje oczyszczony plik tekstowy jako dane surowe.

7.2 Scenariusze lingwistycznego przygotowania danych i mapowania rynku

Po zgromadzeniu dokumentów użytkownik przechodzi do fazy operacji lingwistycznych, wywołując procedury czyszczenia statystycznego (*UC-04: Oczyszczanie i przygotowanie tekstu*). System pobiera surowe pliki, unifikuje wielkość liter, eliminuje pozostałości znaczników strukturalnych oraz znaki specjalne. Następnie wykonywana jest tokenizacja, dzieląca tekst na pojedyncze jednostki leksykalne, z jednoczesną filtracją słów stopu przy użyciu dedykowanych leksykonów ogólnych i dziedzinowych.

Kluczowym punktem zwrotnym w potoku danych, decydującym o biznesowej wartości analizy, jest uruchomienie modułu powiązań rynkowych (*UC-05: Identyfikacja spółek i tickerów*). Użytkownik inicjuje skrypt odpowiedzialny za skanowanie oczyszczonych tokenów pod kątem występowania nazw emitentów GPW. System identyfikuje pełne brzmienia prawne firm, ich skróty oraz unikalne tickery giełdowe. Algorytm realizuje mapowanie wielo-do-wielu, co oznacza, że jeżeli pojedyncza publikacja dotyczy szerokiego kontekstu rynkowego i wymienia kilka podmiotów, artykuł ten zostanie poprawnie przypisany do profilu każdego zidentyfikowanego emitenta.

7.3 Scenariusze modelowania matematycznego i eksploracji Text Mining

Po przygotowaniu bazy danych użytkownik może uruchomić właściwe algorytmy badawcze. Proces rozpoczyna się od analizy sentymentu (*UC-06*), w której skrypt `sentiment.R` porównuje słowa z artykułów ze słownikiem terminów finansowych. System oblicza ogólny wskaźnik nastroju dla

każdego tekstu. Pozwala to użytkownikowi śledzić, jak z upływem czasu zmienia się optymizm i pesymizm na rynku wokół konkretnych spółek.

Dalsza eksploracja realizowana jest poprzez uruchomienie modułów statystycznych. Użytkownik może wywołać analizę frekwencyjną (*UC-07: Analiza najczęściej występujących słów*), dającą wgląd w dominującą strukturę pojęciową korpusu, co stanowi bezpośredni wstęp do wektoryzacji matematycznej (*UC-08: Obliczenie reprezentacji TF-IDF*). Obliczenie wag TF-IDF pozwala systemowi na matematyczne zdefiniowanie unikalności słów kluczowych dla poszczególnych dokumentów. Na bazie tych macierzy użytkownik realizuje dwa zaawansowane scenariusze klastrowania i odkrywania tematów pobocznych.

7.4 Scenariusze prezentacji wyników i utrzymania ciągłości procesowej

Finalna faza interakcji zorientowana jest na syntezę oraz interpretację zgromadzonej wiedzy. Użytkownik uruchamia moduł graficzny (*UC-12: Generowanie wizualizacji wyników*), wymuszając na systemie transformację surowych macierzy i wskaźników sentymentu do postaci czytelnych wykresów pudełkowych, liniowych trendów czasowych oraz chmur tagów. Następnie inicjowany jest kluczowy proces raportowania (*UC-13: Generowanie raportu HTML*), w którym narzędzie R Markdown automatycznie kompiluje wszystkie cząstkowe wyniki, opisy metod i wygenerowane grafiki do jednego, spójnego strukturalnie pliku HTML.

W ujęciu długofalowym użytkownik wchodzi w interakcję z systemem poprzez scenariusz iteracyjnej aktualizacji danych (*UC-14: Aktualizacja danych i ponowne wykonanie analizy*). Pozwala on na przyrostowe rozbudowywanie bazy o nowe artykuły z zachowaniem wypracowanej konfiguracji algorytmów.

Nad poprawnością całego cyklu operacyjnego czuwa zautomatyzowany scenariusz obsługi sytuacji wyjątkowych (*UC-15: Obsługa błędów podczas działania systemu*). W przypadku wystąpienia anomalii sprzętowych lub sieciowych, system izoluje błędy, zapisuje szczegółowe parametry awarii w logach diagnostycznych i powiadamia użytkownika o zaistniałym fakcie, dbając jednocześnie o to, by błąd pojedynczego zapisu lub brak pliku słownikowego nie uszkodził struktury dotychczas wygenerowanej bazy danych.

8 Scenariusze użytkownika (user stories)

Scenariusze użytkownika opisują system z perspektywy osób, które będą z niego korzystać w codziennej pracy. W odróżnieniu od technicznych przypadków użycia, które szczegółowo pokazują działanie mechanizmów programu, scenariusze te skupiają się na korzyściach płynących z automatyzacji analizy tekstu (*Text Mining*). Pozwalają one zrozumieć, jakie konkretne cele analityczne osiąga badacz, wykorzystując narzędzie w swojej pracy.

Poniżej przedstawiono główne intencje operacyjne, którymi kieruje się użytkownik podczas eksploatacji systemu, pogrupowane według logicznych faz analizy finansowej.

8.1 Automatyzacja agregacji danych i kontrola środowiska składowania

Główną potrzebą użytkownika w początkowej fazie pracy jest eliminacja czaso- i pracochłonnych procesów manualnego kopiowania treści z sieci. Jako badacz, użytkownik oczekuje narzędzia, które autonomicznie i masowo pobierze zarówno najświeższe komunikaty rynkowe za pośrednictwem kanałów RSS, jak i głębokie zasoby archiwalne portalu Bankier.pl. Dostęp do zróżnicowanego horyzontu czasowego jest kluczowy dla budowy reprezentatywnej statystycznie próby badawczej. Podczas tego procesu system musi bezwzględnie zabezpieczać strukturę pobieranych metadanych (takich jak unikalne sygnatury czasowe, tytuły, adresy URL czy leady), co umożliwi użytkownikowi późniejsze precyzyjne filtrowanie i chronologiczne sortowanie wyników.

8.2 Lingwistyczne przygotowanie korpusu i mapowanie podmiotów GPW

W fazie przetwarzania wstępnego nadrzędnym celem użytkownika jest uzyskanie maksymalnie oczyszczonego, wartościowego pod względem analitycznym materiału tekstowego. Analityk oczekuje, że algorytmy preprocessingu automatycznie odetną wszelki szum techniczny, zunifikuja wielkość liter oraz przeprowadzą standaryzowaną tokenizację. Bardzo ważnym elementem tego scenariusza jest oczyszczenie tekstów z ogólnych oraz branżowych słów stopu przy użyciu zewnętrznych baz słownikowych, co zapobiega zniekształcaniu końcowych wag statystycznych przez wyrazy neutralne emocjonalnie.

Kolejna kluczowa potrzeba dotyczy automatyzacji powiązań rynkowych. Użytkownik chce, aby system potrafił samodzielnie identyfikować oficjalne tickery giełdowe, skróty biznesowe oraz pełne nazwy prawne spółek notowanych na Giełdzie Papierów Wartościowych w Warszawie. System musi skutecznie radzić sobie z polską fleksją i odmianą nazw własnych przez przypadki, aby artykuły pisane różnym stylem językowym trafiały do profilu jednego, konkretnego emitenta. Pozwala to na prowadzenie rzetelnych analiz celowanych, ukierunkowanych na badanie nastrojów wokół wybranych podmiotów gospodarczych.

8.3 Eksploracja statystyczna i matematyczne modelowanie tematów

W warstwie analitycznej intencją użytkownika jest wyjście poza prostą, intuicyjną ocenę tekstów i zastąpienie jej mierzalnymi wskaźnikami matematycznymi. Badacz oczekuje możliwości ilościowego wyznaczenia sentymentu (pozytywnego, negatywnego i neutralnego) na bazie dedykowanego słownika leksykalnego Loughran & McDonald, zaadaptowanego do polskiego żargonu ekonomicznego. Użytkownik chce badać dystrybucję tych emocji w czasie, aby móc skorelować medialny optymizm lub pesymizm z realnymi wydarzeniami rynkowymi.

W celu głębszego zrozumienia struktury tekstów, użytkownik potrzebuje narzędzi do automatycznego wyliczania wag frekwencyjnych oraz reprezentacji TF-IDF, co pozwala natychmiast wskazać unikalne słowa kluczowe dla poszczególnych dokumentów. Korzystając z tych macierzy, analityk chce realizować zadania uczenia nienadzorowanego: grupować zbliżone artykuły w rozłączne obszary tematyczne za pomocą algorytmu K-means oraz odkrywać ukryte, przenikające się wątki poboczne przy użyciu probabilistycznego modelu LDA. Wynikiem końcowym, jakiego oczekuje użytkownik w tym kroku, jest wygenerowanie unikalnych profili semantycznych dla poszczególnych spółek, ukazujących stały kontekst biznesowy, w jakim dany emitent pojawia się w mediach finansowych.

8.4 Syntetyczne raportowanie i zarządzanie granicami systemu

Ostatni etap pracy zorientowany jest na bezproblemową prezentację i dystrybucję uzyskanej wiedzy. Użytkownik chce uniknąć konieczności interpretowania surowych, wielowymiarowych macierzy liczbowych w konsoli programistycznej. Jego celem jest otrzymanie estetycznych, gotowych wizualizacji danych, takich jak chmury słów, tabele statystyczne czy liniowe wykresy trendów sentymentu. Wszystkie te elementy powinny być automatycznie kompilowane do jednego, autonomicznego raportu w formacie HTML za pomocą pakietu R Markdown. Użytkownik potrzebuje pliku, który można otworzyć w zwykłej przeglądarce internetowej na dowolnym komputerze, co ułatwia prezentację wyników bez potrzeby uruchamiania całego środowiska programistycznego R.

Jednocześnie, jako profesjonalny analityk, użytkownik kładzie duży nacisk na precyzyjne wytyczenie granic interpretacyjnych systemu. Raport końcowy oraz dokumentacja muszą jasno komunikować, że program jest narzędziem stricte lingwistyczno-statystycznym do eksploracji tekstu. Użytkownik wprost wymaga, aby system nie generował automatycznych rekomendacji inwestycyjnych typu „kup/sprzedaj” ani nie prognozował przyszłych ruchów cenowych akcji. Jasne wskazanie tych ograniczeń chroni odbiorcę raportu przed traktowaniem wyników jako gotowych porad finansowych i pozycjonuje system jako bezpieczne rozwiązanie wspomagania decyzji analitycznych.